Бизнес-аналитика и большие данные. Заочники. День 1

1. Подготовка к работе с данными (GitHub, Colab, Google Таблицы)

- Материалы на странице автора на GitHub
- Отчетность - блокнот Jupyter/Colab.
- Google Таблица — инструмент для сбора датасета

2. Игрушечный датасет

- Таблица из пяти столбцов:
  - ник (условное имя),
  - рост (см),
  - вес (кг),
  - длина волос (см),
  - пол (М или Ж).
- Заполняем таблицу:
  - Вместо персональных данных используем никнейм.
- Следим за форматом ввода
  - русские буквы М и Ж
  - целые числа.

3. Markdown в Colab

- Оформляем отчёт средствами текстовых и кодовых ячеек.
- Символ # для заголовков разного уровня (##, ###),
- Звёздочки * для курсива
- Двойные звёздочки ** для жирного текста.
- Добавляем новые ячейки кнопкой [+Текст].
- Перемещаем ячейки в блокноте стрелками вверх-вниз.
- Заголовки и текстовые ячейки с пояснениями
  - игрушечный датасет - определение
  - метаданные – определение
  - метаданные для своего датасета

4. Очистка данных (ETL)

- Приводим данные к единому формату.
- Исправляем ошибки форматирования
  - пробелы перед буквами
  - английские символы вместо русских
- Очистка данных
  - Замена значений (*replace*)
  - Удаление пустых строк
  - Заполнение пропусков NaN.
- Кратко описываем этапы *ETL*:
  - Извлечение (*Extract*)
  - Преобразование (*Transform*)
  - Загрузка (*Load*).
- Проверяем типы данных по столбцам.

5. Таблица DataFrame

- Описываем объект **pandas.DataFrame**.
- Объясняем разницу между методами (функциями) и атрибутами (свойствами, переменными)
    - **df.info()**
    - **df.describe()**
    - **df.shape**
- Сводку по датасету:
    - количество уникальных значений,
    - типы переменных,
    - наличие пропущенных данных (*NaN*).
- Вывести характеристики датасета *df.info()*
- Прокомментировать их значение.

6. Визуализация распределения

- Построить гистограмму по одному числовому признаку (рост, вес).
    - *plt.hist(x, bins=10)*
- Настроить параметры графика:
    - Число интервалов группировки (*bins*),
    - Заголовки по осям plt.xlabel(), plt.ylabel()
    - Общий заголовок plt.title()
    - Легенда (условные обозначения) plt.legend()
- Построить диаграмму рассеяния (*scatter plot*) для двух признаков
    - вес от роста
    - разные маркеры для М и Ж.

7. Инструменты BI

- Описать возможности инструментов
    - Microsoft PowerBI
    - Яндекс Datalens.
- Изучить связь между накопленными частотами и функцией распределения.
- Найти учебный план специальности на сайте вуза
    - *site:uust.ru учебный план прикладная информатика*
    - определить объём самостоятельной работы студентов.
- Определить свой вариант лабораторной работы по номеру зачётки/студенческого билета
- Ознакомиться с примерами экзаменационных билетов на GitHub.

© Арьков В.Ю.