**Лекция 06-07 Распределение**

## 1. Что такое распределение?

В статистике и анализе данных **распределение** — это закономерность появления различных значений случайной величины (например, роста людей). В отличие от бытового смысла («распределить студентов на практику»), здесь речь о математической зависимости: каждому значению соответствует вероятность его появления.

### Задание

- Используя нейросеть, сформулируйте определение РАСПРЕДЕЛЕНИЯ в аналитике данных простыми словами
- Приведите пример этой закономерности из жизни.

---

## 2. Формула распределения вероятностей

Математически распределение описывается формулой вида P(X) = f(x), где X — значение признака, а P — соответствующая ему вероятность. Это функция плотности вероятности (*PDF*).

- Аргумент функции — значения переменной (X);
- Значения на выходе — вероятности этих событий (P).

Формулы — сокращённая запись расчётов для удобства вычислений.

### Задание

- Запишите формулу P(X)
- Объясните своими словами смысл аргумента и результата
- Найдите определения английских терминов DISTRIBUTION и PROBABILITY в английском толковом словаре.

---

## 3. Интерпретация понятия «вероятность»

Вероятность отражает либо нашу уверенность в событии, либо частоту его появления в реальной жизни. Пример: люди среднего роста встречаются чаще, очень высокие/низкие встречаются реже.

**Задание**

- Приведите личный пример события с высокой и низкой вероятностью.
- Объясните разницу между субъективной уверенностью и объективной частотой.

---

**4. Графическое представление распределения**

Существуют две основные визуализации:

- Колоколообразная кривая PDF (плотность вероятности) показывает, как часто встречается каждое значение;
- Функция распределения CDF (кумулятивная кривая) растёт от нуля до единицы и отвечает на вопрос: какая доля наблюдений меньше заданного порога.

**Задание**

- Нарисуйте схематично обе картинки; подпишите оси и поясните их смысл.
- Выясните, как связаны эти две функции и два графика между собой.

---

**5. Нормальное распределение**

Нормальное (гауссовское) распределение характеризуется двумя параметрами: средним значением (мю, μ) и стандартным отклонением (сигма, σ). Оно симметрично относительно среднего.

**Задание**

- Скопируйте из Википедии формулу нормального распределения в нотации TeX и вставьте в свой отчет.
- Вычислите границы интервала ±3σ при среднем=170 см и σ=10 см.
- Сформулируйте правило трёх сигм.
- Как называются значения, выходящие за эти пределы и как с ними можно поступить.

---

**6. Имитационное моделирование**

Для освоения технологий анализа данных часто строят искусственные (синтетические) наборы чисел. Это имитационное моделирование (simulation):

задают тип распределения и генерируют массивы значений с нужными параметрами. Для нормального распределения используют готовые генераторы псевдослучайных чисел.

**Задание**

- Сгенерируйте в Питоне 100 целых чисел со средним 170 и σ=10.
- Преобразуйте результат в обычный список с помощью функции list().

---

**7. Гистограмма**

Гистограмма — это столбиковая диаграмма частот. Сколько чисел из датасета попадает в разные в диапазоны - интервалы группирования. bins - параметр функции hist(). Число интервалов влияет на вид графика: слишком мало — грубые ступеньки, слишком много — шум, гребенка.

- Постройте три варианта гистограммы по сгенерированным данным: с малым, большим и оптимальным количеством интервалов.
- Сделайте выводы об оптимальном выборе числа интрвалов для вашего случая.

---

**8. Доска Гальтона**

Доска Гальтона наглядно демонстрирует образование колоколообразной кривой. Множество шариков падают через решётку штырьков и собираются в «корзинки»/»карманы». Результат напоминает гистограмму.

**Задание**

- Найдите изображение доски Гальтона
- Вставьте картинку в отчёт.
- Вставьте ссылку на источник и автора.
- Опишите принцип работы устройства.

---

**9. Сглаживание гистограммы**

Kernel Density Estimation (KDE) — сглаженная версия гистограммы. Плавная кривая линия вместо грубых столбиков. Главный параметр настройки — bandwidth (ширина ядра, полоса пропускания фильтра), определяющая степень гладкости линии.

**Задание**

- Добавьте на график KDE поверх вашей гистограммы.
- Подберите оптимальный параметр bandwidth так, чтобы линия отражала форму распределения без лишних колебаний.

---

## 10. Теоретическая плотность вероятности

Зная среднее и сигму, можно рассчитать значения функции плотности вероятности по формуле. Можно наложить три изображения: экспериментальную гистограмму, её сглаженную версию (KDE) и теоретическую гауссовскую кривую с теми же параметрами. Для этого нужно задать параметр density=True. Тогда площадь под каждой кривой будет равна единице (требование из теории вероятностей).

**Задание**

- Постройте совмещённый график
  - Гистограмма
  - KDE
  - теоретическая кривая плотности
- Убедитесь, что экспериментальные графики действительно соответствуют теории.

---

## 11. Эмпирическая CDF и квантили

Функция распределения Cumulative Distribution Function (CDF) строится как график накопленных частот P(X).

Квантиль (процентная точка распредления) — обратное действие: задаем вероятность (процент) p и находим соответствующее значение X(P).

**Задание**

- Нарисуйте на бумаге от руки схему нахождения квантиля на графике функции распределения
- Вставьте фото в отчет
- Выясните значение и происхождение слова КВАНТИЛЬ, его перевод на английский
- Постройте совмещенный график функции распределения, сглаженный вариант и теоретическую кривую

## 12. Центральная тенденция

Среднее значение – один из способов оценить ЦЕНТРАЛЬНУЮ ТЕНДЕНЦИЮ для случайной величины. Другие инструменты – мода и медиана.

Для несимметричного распределения работает алфавитное правило. Среднее значение, мода и медиана располагаются в определённом порядке.

### Задание

- Дайте определение терминам МОДА и МЕДИАНА.
- Нарисуйте график плотности вероятности с двумя модами.
- Приведите пример такого распределения.
- Объясните, почему в таком случае нельзя использвоать среднее значение.
- Выясните, как используется медиана для определения прожиточного минимума в РФ.
- Объясните, почему в этом случае медиана лучше, чем средний уровень дохода.
- Нарисуйте схемы асимметрии вправо и влево; расставьте на них среднее, моду и медиану согласно алфавитному правилу и сделайте русские и английские подписи.

© Арьков В.Ю.