

Практика 01. Датасет

Раздел 1. Введение в анализ данных и понятие «игрушечного» датасета

Краткая теория:

Предмет посвящён анализу реальных данных. Для знакомства с методами анализа используются небольшие («игрушечные») наборы данных — это не обязательно «детские» примеры, а данные небольшого размера для экспериментов.

Задание студентам:

- Осмыслить разницу между реальными и игрушечными наборами данных.
 - Привести пример из своей практики (например, задачи ЕГЭ), где используется упрощённый набор данных для объяснения методики решения.
-

Раздел 2. Сбор первичных данных о группе

Краткая теория:

Признак — наблюдаемая характеристика объекта или события; может быть числовой (*height*, *weight*) или текстовый (*gender*). Набор признаков по нескольким объектам образует табличные данные. Электронная таблица — удобный инструмент для хранения таких данных.

Задание студентам:

- Собрать у себя и одноклассников три признака:
 - рост (см),
 - вес (кг),
 - длина волос (см),
 - пол (м/ж).
 - Заполнить электронную таблицу (Excel/Google Таблицы): каждая строка — один человек, столбцы — признаки.
 - Оценить трудоёмкость ручного сбора даже небольших объёмов данных.
-

Раздел 3. Структура таблицы и типы данных

Краткая теория:

В таблицах строки соответствуют отдельным наблюдениям (объектам), столбцы — признакам (переменным). Столбцов обычно меньше, чем строк. Важно различать числовые и категориальные переменные; учитывать регистр при вводе текста (для компьютера "М" ≠ "м").

Задание студентам:

- Проанализировать заполненную таблицу на наличие ошибок ввода (регистр букв, лишние пробелы, нереалистичные значения).
 - Предложить способ стандартизации формата значений (например, привести все буквы к верхнему регистру).
-

Раздел 4. Метаданные: описание набора данных

Краткая теория:

Метаданные — информация о самих данных: что измеряли, как собирали, кто участвовал, когда проводился сбор, единицы измерения. Без метаданных чужой исследователь не сможет правильно интерпретировать результаты.

Задание студентам:

- Сформулировать краткое определение метаданных своими словами.
 - Составить список метаданных для текущего датасета по схеме «**Что? Где? Когда?**», например:
 - Что: студенты очной формы обучения;
 - Где: [название вуза];
 - Когда: октябрь 2026 года.
 - Указать единицы измерения каждого признака.
 - Посоветоваться с нейросетью и дополнить метаданные.
-

Раздел 5. Первичная визуализация данных: диаграмма разброса

Краткая теория:

Диаграмма разброса показывает зависимость двух количественных признаков (X — рост, Y — вес). Оси подписываются осмысленно, указывая единицы измерения. График должен иметь заголовок, отражающий суть исследования («**Студенты Университета, 2026**») и легенду маркеров.

Задание студентам:

- Построить от руки диаграмму разброса на листе бумаги во весь формат (альбомный разворот):
 - ось X — рост (от 150 до 200 см);
 - ось Y — вес (от 50 до 110 кг);
 - нанести точки (М) и звездочки (Ж) согласно данным группы.
- Сделать фото графика и вставить его в отчётную ячейку Google Colab вместе с пояснениями.

Раздел 6. Автоматизация работы: загрузка данных в Python

Краткая теория:

Для автоматизации анализа используют библиотеки pandas (DataFrame, read_excel/read_csv). Нейросети могут генерировать код для загрузки данных и построения графиков по ссылке на таблицу.

Задание студентам:

- Загрузить собранную таблицу через ссылку в Jupyter Notebook/Colab с помощью pandas.
- Выполнить команду генерации кода нейросетью для построения аналогичного графика средствами Python (matplotlib/seaborn).
- Сохранить полученный скрипт и сравнить ручной график с автоматическим.

Итоговое задание

Загрузить ссылку на отчёт в виде блокнота Google Colab, включающего:

- Определение метаданных,
- Метаданные для нашего датасета,
- Фото ручного графика с осями, масштабом, заголовком и легендой,
- Код автоматической загрузки и визуализации данных,
- Выводы о трудозатратах сбора и обработки данных.